

ⵜⴰⵎⴻⵔⴰⵏⵜ | ⵜⴰⵎⴰⵏⴰⵢⵜ
FACULTÉ DES SCIENCES



كلية العلوم
FACULTY OF SCIENCE

Semlalia

PROJET DE MACHINE LEARNING

Analyse et Prédiction des Performances des Étudiants à
l'aide des Techniques de Machine Learning

Dataset utilisé :
Students Performance Dataset (Source : Kaggle)

Réalisée par :

Lina Alouach

l.alouach6956@uca.ac.ma

Encadré par :

PR. FAHD KALLOUBI

Module : Machine Learning

Filière : Licence en Ingénierie des Systèmes Informatiques

Année universitaire 2026-2027

1. Introduction

L'objectif de ce projet est d'appliquer différentes techniques de Machine Learning sur le dataset *Students Performance* provenant de Kaggle. Ce dataset contient des informations démographiques ainsi que les résultats scolaires de 1000 étudiants.

Le projet couvre les trois grandes catégories du Machine Learning :

- Régression : prédiction des notes des étudiants.
- Classification : prédiction de la réussite ou de l'échec scolaire.
- Clustering : identification de groupes d'étudiants ayant des profils similaires.

Les travaux réalisés comprennent l'exploration des données, leur prétraitement, l'application de plusieurs modèles supervisés et non supervisés ainsi que l'évaluation des performances obtenues.

2. Présentation du Dataset

Le dataset utilisé est le *Students Performance Dataset* disponible sur Kaggle. Il contient 1000 observations et 8 variables.

Les variables disponibles sont :

- Gender
- Race/Ethnicity
- Parental Level of Education
- Lunch
- Test Preparation Course
- Math Score
- Reading Score
- Writing Score

L'analyse exploratoire a montré que le dataset est propre :

- Nombre d'observations : 1000
- Nombre de variables : 8
- Valeurs manquantes : 0
- Doublons : 0

Les statistiques descriptives montrent que la moyenne des notes est :

- Math Score : 66.09
- Reading Score : 69.17

- Writing Score : 68.05

Ces résultats indiquent que les performances des étudiants sont relativement équilibrées entre les trois matières.

3. Exploration et Prétraitement des Données

3.1 Visualisation

Plusieurs visualisations ont été réalisées :

- Histogrammes des notes
- Matrice de corrélation (Heatmap)

L'analyse montre une forte corrélation positive entre les scores en mathématiques, lecture et écriture. Les étudiants obtenant de bons résultats dans une matière tendent généralement à obtenir de bonnes performances dans les autres.

3.2 Prétraitement

Les variables catégorielles ont été transformées en variables numériques à l'aide de la méthode :

- One-Hot Encoding (get_dummies)

Cette étape est indispensable afin de permettre aux algorithmes de Machine Learning de traiter correctement les données.

4. Apprentissage Supervisé

4.1 Régression

Objectif : Prédire la note en mathématiques à partir des autres variables du dataset.

Les performances ont été évaluées à l'aide du coefficient de détermination R^2 et de l'erreur quadratique moyenne MSE.

Résultats : Coefficient de détermination (R^2)

Modèle	R^2
Linear Regression	0.8804
Ridge Regression	0.8803
Random Forest Regressor	0.8492
Lasso Regression	0.8336
Elastic Net	0.7632

Modèle	R ²
Decision Tree Regressor	0.7384
KNN Regressor	0.6960

Résultats : Erreur Quadratique Moyenne (MSE)

Modèle	MSE
Linear Regression	29.10
Ridge Regression	29.12
Random Forest Regressor	36.70
Lasso Regression	40.49
Elastic Net	57.63
Decision Tree Regressor	63.66
KNN Regressor	73.98

Analyse :

Les meilleurs résultats sont obtenus par :

- ✓ Linear Regression
- ✓ Ridge Regression

Ces deux modèles expliquent environ 88 % de la variance des notes en mathématiques.

4.2 Classification :

Objectif : Prédire la réussite scolaire.

Un étudiant est considéré comme ayant réussi lorsque sa note en mathématiques est supérieure ou égale à 50.

Modèles testés

- Decision Tree
- KNN
- Logistic Regression
- Random Forest

- SVM
- Perceptron
- AdaBoost
- Gradient Boosting
- Bagging

Résultats :

Modèle	Accuracy
Logistic Regression	0.96
Random Forest	0.94
AdaBoost	0.935
Gradient Boosting	0.935
Decision Tree	0.93
Bagging	0.925
SVM	0.88
KNN	0.87
Perceptron	0.86

Analyse :

La Logistic Regression obtient les meilleures performances avec une précision de 96 %.

Les méthodes d'ensemble (Random Forest, AdaBoost et Gradient Boosting) produisent également d'excellents résultats.

5. Évaluation des Modèles

5.1 Matrice de Confusion

Une matrice de confusion a été utilisée afin d'évaluer les performances des modèles de classification.

Elle permet de distinguer :

- Vrais positifs
- Faux positifs

- Vrais négatifs
- Faux négatifs

5.2 Classification Report

Résultats obtenus avec Random Forest :

Métrique	Valeur
Precision	0.94
Recall	0.94
F1-Score	0.94

Ces résultats montrent un bon équilibre entre précision et rappel.

5.3 Validation Croisée

K-Fold Cross Validation

Accuracy moyenne :

0.912

Leave-One-Out

Accuracy moyenne :

0.916

Les performances restent stables quelle que soit la méthode de validation utilisée, ce qui confirme la robustesse des modèles.

5.4 Optimisation des Hyperparamètres

Afin d'améliorer davantage les performances, une optimisation des hyperparamètres a été réalisée à l'aide de Randomized Search.

Les meilleurs paramètres obtenus pour Random Forest sont :

- n_estimators = 200
- max_depth = 5

Cette étape permet d'améliorer les performances du modèle tout en limitant le surapprentissage.

6. Apprentissage Non Supervisé

L'apprentissage non supervisé a été utilisé afin d'identifier automatiquement des groupes d'étudiants présentant des profils similaires.

Les variables utilisées sont :

- Math Score
- Reading Score
- Writing Score

Avant l'application des algorithmes, les données ont été normalisées à l'aide de StandardScaler.

6.1 K-Means++

L'algorithme K-Means++ a permis de partitionner les étudiants en trois groupes distincts selon leurs performances académiques.

Les clusters obtenus représentent globalement :

- Étudiants à faible performance
- Étudiants à performance moyenne
- Étudiants à forte performance

6.2 Bisecting K-Means

Une variante hiérarchique de K-Means a également été utilisée.

Cette méthode partitionne progressivement les données en sous-groupes plus homogènes.

6.3 DBSCAN

DBSCAN permet d'identifier automatiquement les groupes d'étudiants ainsi que les éventuelles observations atypiques (outliers).

Cette approche ne nécessite pas la définition préalable du nombre de clusters.

6.4 Clustering Hiérarchique

Le clustering hiérarchique agglomératif a été utilisé avec trois groupes. Cette méthode fusionne progressivement les observations les plus proches afin de construire une hiérarchie de clusters.

Les résultats obtenus confirment l'existence de plusieurs profils académiques distincts au sein du dataset.

7. Conclusion

Ce projet a permis d'appliquer plusieurs techniques de Machine Learning sur le dataset Students Performance. **En régression**, Linear Regression et Ridge Regression ont obtenu les meilleures performances avec un **R² supérieur à 0.88**. **En classification**, Logistic Regression a atteint **une accuracy de 96 %**. Les méthodes de clustering ont permis d'identifier différents profils d'étudiants selon leurs résultats académiques. Ces résultats montrent l'efficacité des techniques de Machine Learning pour la prédiction et l'analyse des performances scolaires.